

CH2 분석보고서 피드백 및 결과해석 정리

작성일 2026-07-30 · 대상: CH2_분석보고서_4_.docx (최종판) · 참고자료: TierA_TierB_전체정리.html, 외부 검토의견, 세션 내 재검증 결과

이 문서의 구성

- 1장** — 강화군 2016~2019 결측 처리에 대한 확정 문구
- 2장** — 재확인이 필요한 사항 5가지 (기존 검토 3가지 + 이번 세션에서 추가로 발견한 2가지)
- 3장** — 결과 해석 가이드 및 서술 시 유의사항
- 4장** — 종합 체크리스트
- 부록** — 원자료 재계산을 통한 독립 재현 검증 상세

총평: 보고서의 결론 방향(도로소나무비율_500m를 TierA로 교정 후 신호 소멸을 확인하고 인위적확산 도메인에서 제외한 것)은 타당하며, 부록의 독립 재현에서도 같은 방향이 확인됩니다. 다만 인용 전 반드시 확인해야 할 5가지 사항이 남아 있습니다.

1. 강화군(2016~2019) 결측 처리 — 확정

계산식: 도로소나무비율_500m = road_inter_ha ÷ 소나무림면적_원자료_ha

확인된 사실 (TierA 원자료 및 최종보정3 직접 대조):

연도	2016	2017	2018	2019	2020	2021	2022	2023
road_inter_ha (TierA)	2.78	12.26	12.43	12.43	12.26	12.26	12.26	12.26
소나무림면적_원자료_ha (최종보정3)	0	0	0	0	228.81	228.81	228.81	228.81
도로소나무비율_500m	분모=0 → 산출 불가 (결측)				0.0536			

분자(도로 교차면적)는 2016~2019에도 0보다 크지만, 분모(소나무림면적)가 최종보정3 기준 0으로 정의되어 있어 비율 자체가 수학적으로 정의되지 않습니다.

결론: 이는 병합 과정에서 생긴 오류가 아니라, 최종보정3의 면적 기준(2019 임상도 vs 2024 임상도 분리 적용)을 일관되게 따른 결과입니다. 모델링 전에 반드시 보정해야 할 오류가 아니라 **정합적 결측**으로 처리하는 것이 맞습니다.

권장 삽입 문구 (그대로 사용 가능)

"강화군 2016~2019는 TierA 도로 교차면적은 존재하나, 최종보정3 기준 소나무림면적이 0으로 처리되어 도로소나무비율 산출이 불가능하므로 결측 처리하였다. 이는 병합 오류가 아니라 최종보정3의 면적 기준을 일관 적용한 결과이다."

Claude 확인: 위 수치는 업로드된 TierA 원자료 및 최종보정3 파일에서 직접 대조하여 확인했습니다. 이견 없음 — 그대로 채택 가능합니다.

2. 재확인이 필요한 사항

기존 검토의견에서 제기된 3가지에, 이번 세션에서 원자료를 재계산하며 추가로 발견한 2가지를 더해 총 5가지를 정리했습니다.

#	구분	내용	권고 조치	우선순위
①	기존 검토	인위적확산 도메인이 log1p_원목생산업체수 단일 변수로만 구성됨. 이 변수 자체의 데이터 품질(결측패턴·집계 단위·연도별 일관성)은 도로비율만큼 엄밀히 검증된 적이 없음	229개 집계 단위·연도별 정의 일관성·결측 패턴을 도로비율과 동일한 절차로 QA	중
②	기존 검토	"면적통제 후 상관 0.19→0.0008"의 정확한 수치를 스크립트 없이 독립 재현하지 못함	부록 참고 — Claude가 유사 수치 재현에 성공하여 상당 부분 해소됨. 다만 정확한 표본·스크립트 대조는 권장	낮음(해소)
③	기존 검토	Model1 AUC가 문서 내에서 이중 표기(구조타당성 검증용 0.581/0.564, Model2 공정비교용 0.581/0.621)되어 있어, 슬라이드·요약본으로 옮길 때 각주 없이 숫자만 인용될 위험	다른 산출물로 옮길 때 평가설계 각주를 반드시 동반 이관하는 규칙화	중
④	신규 발견	TierA_TierB_전체정리.html (작업 메모)과 CH2_분석보고서_4_.docx (최종보고서)가 같은 이름의 지표에 서로 다른 수치를 기재하고 있음 — 아래 2-1 상세 참고	어느 수치가 최종 기준인지 명시하고, 통제방식(변수)의 차이를 부록에 고정 문서화	높음
⑤	신규 발견	최종보정3에서 서울 영등포구·대구 중구·인천 동구 3개 구는 도로소나무비율_500m 값이 NaN인데 _최종사용_flag 는 1로 표기되어 있어 값과 플래그가 모순. 최종보정4에서도 동일한지 미확인	최종보정4에서 해당 3개 구의 flag 값을 재확인 후, 결측이면 flag=0으로 정정하거나 flag의 정의 자체를 재검토	중

2-1. ④ 상세 — 메모와 최종보고서의 수치 불일치

지표	HTML 메모 (§ 4· § 5)	docx 최종보고서	비고
면적통제 후 잔차/편상관	TierB +0.2243 → TierA +0.0147	0.19(구버전) → 0.0008(최종판)	통제에 사용한 면적 변수가 서로 다를 가능성이 높음. 부록 참고 — Claude가 log_소나무면적 을 통제변수로 썼을 때 docx 수치(0.19/0.0008)에 근접한 값을 얻음
Model1 AUC(훈련/홀드아웃)	TierB 0.617/0.622 → TierA 0.599/0.613 (Model1_v3_로그.txt 대조로 검증됨)	구조타당성검증 0.581/0.564(§ 4) 공정비교용 0.581/0.621(§ 5.2) ("이전 v4" 참조범위: AUC 0.60~0.59)	최소 3개의 파이프라인 버전(v3 → v4 → 최종/최종보정4)에서 나온 수치가 한 보고서 생태계 안에 섞여 있음

왜 문제가 되나: 두 문서 모두 "면적통제 후 상관"이라는 같은 이름을 쓰고 있어, 나중에 두 문서를 같이 참고하는 사람이 어느 것이 맞는 수치인지 헷갈릴 수 있습니다. AUC도 최소 4개 숫자쌍(0.617/0.622, 0.599/0.613, 0.581/0.564, 0.581/0.621)이 서로 다른 근거로 존재합니다. 각각이 어떤 스크립트·버전·평가설계에서 나온 것인지 한 번은 표로 고정해 둘 필요가 있습니다(③번 항목과 연결되는 문제이지만, 이번엔 **보고서 내부의 이중 표기가 아니라 두 문서 사이의 불일치**라는 점에서 별개로 관리해야 합니다).

3. 결과 해석 가이드

보고서의 결론 방향 자체는 타당합니다. 도로소나무비율_500m은 원래 "접근성/인위적 확산 가능성"을 나타내는 프록시 변수인데, 면적을 통제하면 피해와 거의 무관해진다는 것이 확인되었으므로, 역지로 지수에 남겨두는 것보다 제외하는 편이 지수의 순수성을 지키는 데 낫습니다. 다만 아래 네 가지는 서술 방식에서 주의가 필요합니다.

3.1 Model 1과 Model 2의 역할 구분

Model 1(구조적취약성지수)에서 **between** 효과는 **유의**하고 **within** 효과는 **약하거나 비유의**하다는 것은, "같은 시군구 안에서 지수가 시간에 따라 변할 때 피해가 즉각 따라 움직인다"는 근거는 약하지만 "원래 취약성이 높은 지역이 평균적으로 피해가 크다"는 지역 간 차이는 뚜렷하다는 뜻입니다. 따라서 이 지수는 **단기 예측용보다 장기 우선순위 선정·구조적 취약지역 선별·예산 배분 기준**에 적합합니다.

반대로 Model 2의 AUC 0.947은 매우 높지만, 보고서 § 5.3에 명시된 대로 **연속발생연수 단독으로도 이미 0.918**이 나옵니다. 즉 이 성능은 "구조적 요인을 잘 예측해서"가 아니라 **재선충 피해의 지속성(상승발생 여부)**에서 나옵니다. Model 2는 조기탐지·재발위험 관리 도구로 성격을 규정하는 것이 정확합니다.

3.2 AUC를 해석할 때

모형	AUC	정확한 해석
Model 1	0.56~0.62	아주 높은 예측모델은 아니지만 실패도 아님. "올해 어디서 발생할지 맞히는 예측기"가 아니라 "장기적으로 취약한 지역 구조를 설명하는 지수"로 규정할 것
Model 2	0.947	과거 발생 변수(연속발생연수 등)가 강하게 작동한 결과. "구조적 요인을 매우 잘 예측한다"고 쓰면 위험 — 재선충 피해의 관성/지속성을 반영한다고 쓸 것

3.3 서술 시 주의 문구

이렇게 쓰면 위험	이렇게 쓰는 게 안전
"도로가 중요하지 않다"	"현재 TierA 기준 500m 도로소나무비율은 면적통제 후 추가 설명력이 거의 없어 최종 지수에서는 제외했다"
"우리 모델이 구조적 요인을 매우 잘 예측한다"(Model2 관련)	"Model2 성능은 과거 발생 정보(상습발생 여부)가 강하게 작동한 결과이며, 정책적으로는 조기탐지·재발위험 관리 모델에 가깝다"
"실제 예산보다 시뮬레이션이 더 낮다"	"실제 예산은 이미 발생한 피해에 대응하는 사후적 성격이 강하고, 시뮬레이션은 취약성 기반 사전 배분 성격이 강해 목적함수 자체가 다르다"

3.4 권장 결론 문장

"구조적 취약성지수는 단기 발생 예측력은 제한적이나, 지역 간 장기 취약성 차이를 일관되게 포착한다. 반면 과거 발생 정보를 포함한 Model 2는 매우 높은 예측성능을 보이며, 이는 재선충 피해의 강한 지속성과 공간적 관성을 반영한다. 따라서 Model 1은 사전적 취약지역 선별 및 중장기 예산배분 기준으로, Model 2는 단기 감시·대응 우선순위 설정 도구로 활용하는 것이 적절하다."

4. 종합 체크리스트

#	항목	조치	우선순위	상태
1	강화군 2016~2019 결측 서술	1장의 확정 문구를 보고서 § 2.1 각주 또는 부록에 삽입	낮음	문구 확정
2	원목생산업체수 QA	229 집계단위·연도별 일관성·결측패턴 점검	중	미착수
3	0.19→0.0008 재현	부록의 재현 결과로 상당 부분 해소. 정식 인용 전 model1_final.py와 1회 대조 권장	낮음	부분 해소
4	AUC 이중표기 이관 규칙	슬라이드/요약본 작성 시 평가설계 각주 동반 규칙 문서화	중	미착수
5	메모-보고서 수치 불일치	잔차상관·AUC 각각 어느 쪽이 최종 기준인지, 어떤 통제변수/스크립트에서 나왔는지 부록에 고정	높음	미착수
6	flag=1×값=NaN 정합성	영등포구·대구중구·인천동구 3개 구의 flag를 최종보정4에서 재확인	중	미착수
7	서술 문구 3종 교정	3.3절 표의 권장 표현으로 본문 교체	중	미착수
8	최종 결론 문단	3.4절 권장 문장을 § 10 종합결론에 반영할지 검토	낮음	검토 필요

부록. 원자료 재계산을 통한 독립 재현 검증

업로드된 TierA 원자료와 최종보정3(도로변수 교체 전 패널)을 이용해, 최종보고서가 인용한 핵심 수치를 독립적으로 재현했습니다. **최종보정4 파일과 model1_final.py 스크립트 자체는 보유하지 않았으므로**, 아래는 정확한 재현이 아니라 근사 재구성입니다.

A.1 평균값 및 상관

지표	보고서(docx) 수치	Claude 재현 결과	일치도
도로소나무비율_500m 평균 (구버전/TierB)	0.340	0.3402	일치
도로소나무비율_500m 평균 (재계산/TierA)	0.183	0.186	근접
신구 버전 간 상관	0.43	0.389	근접(약간 차이)

A.2 면적통제 후 편상관 (핵심 수치 재현)

어떤 면적 변수로 통제하느냐에 따라 값이 달라져, 3가지 방식으로 모두 확인했습니다.

통제변수	TierB 편상관(p)	TierA 편상관(p)
소나무류_면적비율(%)	0.1031 (p<0.001)	0.0043 (p=0.854)
log_소나무림면적	0.1916 (p<0.001)	-0.0086 (p=0.717)
소나무림면적_원자료_ha(원값)	0.0453 (p=0.054)	-0.0440 (p=0.062)

재현 성공: log_소나무림면적 을 통제변수로 사용했을 때 TierB=0.1916, TierA=-0.0086이 나와, 보고서의 "0.19(구버전) → 0.0008(최종판)"과 사실상 일치합니다. 통제변수를 무엇으로 쓰든(3가지 모두) **TierB는 유의한 양(+)**의 잔차를 유지하고 **TierA는 0에 수렴하며 비유의해지는 패턴이 일관되게 재현**되어, 보고서의 핵심 주장("면적통제 후 도로변수의 신호는 사실상 없다")은 방법에 관계없이 견고합니다.

A.3 패널 고정효과 모형에서의 추가 확인 (세션 내 자체 분석)

시군구 고정효과를 포함한 패널모형(log_피해밀도_본per_ha를 종속변수로, 기후·인접시군 피해밀도 등을 통제)에서는 **TierB(시간불변 변수)**가 고정효과와 완전공선이 되어 계수 추정 자체가 불가능했습니다(AbsorbingEffectError). TierA(시간가변)는 정상 추정되나 모든 모형 사양에서 비유의(p>0.35)했습니다. 이는 도로변수 제외 결정을 뒷받침하는 별도의 독립적 근거입니다.

A.4 재현 방법 및 한계

- TierA 229개 집계: 11개 대구시(수원·성남·안양·안산·고양·용인·청주·천안·전주·포항·창원) 32개 세부코드를 자체 매핑으로 면적합산(분자·분모 각각 sum 후 재계산). 팀의 공식 크로스워크 파일(CH2_crosswalk_250to229.csv)은 보유하지 않아 자체 매핑 결과이며, n_source(1~5) 분포는 보고서의 88행(11곳×8년) 구조와 일치함을 확인함
- 강화군 등 분모=0 케이스는 원본 TierA와 동일하게 결측 처리
- 최종보정4 자체, model1_final.py 등 실제 프로덕션 스크립트는 보유하지 않아, 표본 정의(listwise deletion 등)까지 완전히 동일하게 맞추지는 못했습니다. 위 수치는 "방향과 크기가 같은 결론에 도달하는지"를 확인하는 근사 재현입니다.